

Relationale Relevanzfelder

für große Sprachmodelle

Ein emergenter Ansatz zur Rekonstruktion menschlicher
Innenwelt aus Sprache, Geschichte und Konsequenzen

Thomas Mack

Version 3.0 · 17. September 2026

Konzeptioneller Forschungsentwurf

Nicht nur menschliche Bewertungen werden zum Gegenstand des Lernens, sondern auch die Beziehungen, durch die sie entstehen, Folgen haben und sich verändern. Die rekursive Metaebene ist Teil dieser Struktur, kein nachträglich hinzugefügter Beobachter.

Inhalt

Kurzfassung.....	3
1. Ausgangspunkt und zentrale Hypothese	3
2. Menschliche Innenwelt als Bezugsrahmen.....	4
3. Equilibrium als Ursprung der Relevanzbildung	4
4. Sprache, Geschichte und Konsequenzen	5
5. Lernen aus unvollständigen Geschichten	6
6. Die rekursive Metaebene.....	7
7. Anna und Paul: Ein zeitlicher Zusammenhang	7
8. Der menschliche Maßstab umfasst auch das angestrebte Sein	9
9. Funktionale Rekonstruktion und die Grenze körperlicher Erfahrung	9
10. Emergenz statt vollständig vorgegebener Kategorien	10
11. Ein mögliches elementares Lernprinzip	11
12. Mögliche technische Umsetzungen	11
13. Bezug zu bestehenden Forschungsansätzen	12
14. Wahrheit, Alignment und mögliche emergente Fähigkeiten	14
15. Ein erstes Forschungsprogramm	15
16. Aussagekraft, Grenzen und offene Fragen	16
17. Der mögliche eigenständige Beitrag	17
18. Schlussfolgerung.....	17
Versionshinweis	18
Literatur	19

Kurzfassung

Relationale Relevanzfelder, im Folgenden auch Relational Relevance Fields oder RRF, bezeichnen den Vorschlag, die funktionale Struktur menschlicher Innenwelt aus ihren sprachlichen, biografischen und historischen Spuren zu rekonstruieren. Gemeint ist nicht nur, welche Bedeutung Menschen einer Erscheinung zuschreiben, sondern wie diese Bedeutung aus ihrem Zustand, ihren Erwartungen und ihren Beziehungen entsteht, Entscheidungen beeinflusst und durch deren Folgen verändert wird.

Die zugrunde liegende Arbeitshypothese betrachtet menschliche Bewertung als Orientierung an einem subjektiv erwarteten günstigeren Seinszustand. Körperliche Sicherheit, gedankliche Orientierung, emotionales Equilibrium und kognitive Entlastung bilden dabei miteinander verbundene Gesichtspunkte. Ihre Gewichtung ist weder notwendig bewusst noch immer zutreffend. Gerade Irrtümer, Selbsttäuschungen, widersprüchliche Bedürfnisse und spätere Korrekturen gehören zum Gegenstand des Modells.

Die entscheidende Metaebene entsteht aus Beziehungen zwischen solchen Bewertungen, ihren Voraussetzungen, ihren Folgen und ihrer Veränderung. Auch die Differenz zwischen gefühlter und tatsächlich begründeter Sicherheit wird innerhalb dieses Gefüges erfasst. Sie ist kein außerhalb des Ansatzes verbleibender Einwand.

Ein künstliches System soll diese Ordnung nicht als vollständige menschliche Wertetabelle erhalten. Sie soll aus dem Lernen sehr vieler verschachtelter, perspektivabhängiger und zeitlich verlaufender Beziehungen hervorgehen. Vollständige Lebensgeschichten werden dafür nicht vorausgesetzt. Unvollständige Zeugnisse können allgemeine Strukturen erschließbar machen, ohne unbekannte Einzelfälle nachträglich zu vervollständigen.

Die Forschungsfrage lautet, ob daraus eine verhaltenswirksame Form des Verstehens entstehen kann: ein System, das nicht nur menschliche Urteile beschreibt, sondern Zusammenhänge von Erleben, Handlung und Folge für seine eigene Informationsverarbeitung nutzt. Besseres Alignment, weniger Halluzinationen und weitergehende emergente Fähigkeiten sind mögliche Folgehypothesen. Dieses Dokument berichtet keine bereits durchgeführten RRF-Experimente.

1. Ausgangspunkt und zentrale Hypothese

Ein System kann zahlreiche Zusammenhänge sprachlich darstellen, ohne sie in einer konkreten Situation zuverlässig zu einer tragfähigen Orientierung zu verbinden. Für RRF ist deshalb nicht allein entscheidend, ob eine KI weiß, was Vertrauen, Gefahr oder Wahrheit bedeuten. Entscheidend ist, ob sie erfassen kann, welche Funktion diese Begriffe innerhalb menschlich erlebter Wirklichkeit besitzen.

Der Ansatz beginnt nicht mit der Annahme, bisherige Sprachmodelle hätten überhaupt keine inneren Weltmodelle oder Bewertungen. Untersuchungen an Othello-GPT fanden beispielsweise eine interne Repräsentation des Spielzustands, obwohl das Modell auf die Vorhersage von Spielzügen trainiert worden war. Eingriffe in diese Repräsentation beeinflussten seine Ausgaben. Eine einfache Vorhersageaufgabe kann somit zumindest in einem begrenzten Versuchsaufbau eine funktional wirksame innere Struktur hervorbringen. [1]

Die weiterführende Hypothese lautet:

Aus den miteinander verbundenen Spuren menschlichen Erlebens, Bewertens und Handelns könnte ein künstliches System eine interne Ordnung lernen, die rekonstruiert, wie Wirklichkeit für Menschen Bedeutung erhält und wie sich diese Bedeutung durch Erfahrung verändert.

RRF sind damit weder lediglich eine Ergänzung von Weltwissen noch eine nachträgliche Bewertung fertiger Antworten. Sie zielen auf die Entstehungs- und Veränderungsstruktur menschlicher Relevanz und deren mögliche Integration in künstliche Informationsverarbeitung.

2. Menschliche Innenwelt als Bezugsrahmen

Mit Innenwelt ist hier das Gefüge gemeint, in dem Wahrnehmungen, Erinnerungen, Erwartungen, Gefühle, Bedürfnisse und Selbstvorstellungen für einen Menschen miteinander in Beziehung stehen. Eine Erscheinung erhält ihre Relevanz nicht unabhängig von diesem Gefüge.

Ein Feuer kann Wärme, Geborgenheit oder eine existenzielle Bedrohung bedeuten. Eine Nachricht kann Orientierung schaffen oder das bisherige Selbstverständnis erschüttern. Derselbe Sachverhalt kann für verschiedene Menschen, aber auch für denselben Menschen zu unterschiedlichen Zeitpunkten, etwas grundlegend anderes bedeuten.

Der philosophische Ausgangspunkt lautet: Für einen Menschen ist Wirklichkeit nur innerhalb seiner eigenen Erfahrung zugänglich. Auch eine Erkenntnis über seine Irrtümer tritt wieder in diese Wirklichkeit ein und verändert sie. Diese Festlegung betrifft den Zugang zur Wirklichkeit; sie erklärt weder alle Behauptungen für gleich richtig noch setzt sie voraus, dass außerhalb der Erfahrung keine Welt besteht.

Ein System, das menschliche Wirklichkeit funktional rekonstruieren soll, müsste deshalb Perspektiven modellieren, ohne sie miteinander zu verwechseln. Es müsste erfassen können, was jemand weiß, vermutet, erwartet, befürchtet oder noch nicht erkennen kann. Die Rekonstruktion einer Perspektive bedeutet nicht, jede darin enthaltene Überzeugung als Tatsachenbeschreibung zu übernehmen.

Der Anspruch ist nicht, einen allwissenden Standpunkt außerhalb menschlicher Erfahrung einzurichten. Er besteht darin, Beziehungen zwischen vielen begrenzten Perspektiven, ihren Grundlagen und ihren Veränderungen erschließbar zu machen.

3. Equilibrium als Ursprung der Relevanzbildung

Die anthropologische Arbeitshypothese dieses Ansatzes lautet: Menschen bewerten Erscheinungen danach, welche Beziehung sie zu einem Zustand besitzen, den sie aus ihrer jeweiligen Perspektive als günstiger, sicherer, stimmiger oder tragfähiger erwarten. Diese Orientierung wird hier als Streben nach einem optimalen Seinszustand beziehungsweise einem dynamischen Equilibrium bezeichnet.

Darin stehen körperliche Sicherheit, gedankliche Sicherheit, emotionale Ausgeglichenheit und die Begrenzung geistigen Aufwands miteinander in Beziehung. Gedankliche Sicherheit bezeichnet beispielsweise die Möglichkeit, sich in einer Situation zu orientieren, Erwartungen zu bilden und nicht jede Voraussetzung ständig neu überprüfen zu müssen. Die jeweils erwartete Verbesserung muss weder bewusst berechnet noch tatsächlich erreicht werden.

Equilibrium bedeutet dabei nicht dauernde Ruhe, maximale Bequemlichkeit oder die Vermeidung jeder Belastung. Ein schwieriges Gespräch, das Eingeständnis eines Irrtums oder das Erlernen einer anspruchsvollen Fähigkeit kann kurzfristig Aufwand und Verunsicherung erhöhen. Innerhalb eines größeren zeitlichen Zusammenhangs kann damit dennoch eine bessere Orientierung verbunden sein.

Ebenso können verschiedene Bestrebungen miteinander kollidieren. Das Bedürfnis nach Bindung kann mit dem Wunsch nach Selbstschutz in Spannung stehen. Eine vertraute Deutung kann entlasten, obwohl ihre Konsequenzen problematisch werden. Auch die Gewichtung dieser Konflikte und deren spätere Neubewertung gehören zum Modell.

RRF sollen diese Orientierung rekonstruieren, nicht einen einzelnen vorgegebenen Wohlfühlwert maximieren. Der Begriff Equilibrium benennt zunächst eine Hypothese über die Organisation von Bewertung, keine fertige technische Belohnungsfunktion.

Verwandte Bezugspunkte finden sich in Barretts Theorie konstruierter Emotionen, die körperbezogene Verarbeitung, Vorhersage und Begriffsbildung zusammen betrachtet, sowie in homeostatisch reguliertem Reinforcement Learning, das Motivation über die Regulation innerer Zustände modelliert. Diese Arbeiten begründen eine fachliche Nachbarschaft, nicht die Gültigkeit aller RRF-Annahmen. [4] [8]

4. Sprache, Geschichte und Konsequenzen

Menschliche Relevanz ist nach dieser Theorie nicht ausschließlich im Wortlaut einzelner Äußerungen enthalten. Sie wird ebenso in den Geschichten sichtbar, die aus Bewertungen und Handlungen entstehen, und in den Konsequenzen, mit denen Menschen anschließend umgehen müssen.

Der grundlegende Zusammenhang lässt sich vereinfacht so darstellen:

Erleben → Bewertung → Erwartung → Entscheidung und Handlung → Konsequenz → neue Erfahrung → veränderte Bewertung.

Dies ist kein Anspruch auf eine stets lineare Abfolge. Erwartungen verändern Wahrnehmungen; die Handlungen anderer wirken zurück; frühere Erfahrungen bleiben wirksam. Die Darstellung bezeichnet einen wiederkehrenden Zusammenhang, keinen starren Ablaufplan.

Eine Äußerung wie „Damals hielt ich das für die richtige Entscheidung“ enthält eine Beziehung zwischen früherer Überzeugung und gegenwärtigem Urteil. Ein dokumentierter Misserfolg kann eine Erwartung widerlegen. Eine spätere Entschuldigung kann zeigen, dass jemand seine Handlung nun anders beurteilt. Geschichte umfasst in diesem Sinn sowohl persönliche Verläufe als auch das Zusammenspiel vieler Menschen über längere Zeiträume.

Sprache ist ein Zugang zu diesen Vorgängen, nicht deren einzige Ursache. Ergänzende Daten über Handlungen, Ereignisse und Ergebnisse könnten die Rekonstruktion erweitern. Wo lediglich ein Bericht über eine Folge vorliegt, bleibt dieser Bericht von einer unabhängig bestätigten Folge unterscheidbar.

Der Lerngegenstand ist damit nicht nur, wie Menschen erzählen. Er ist auch, wie die in ihren Zeugnissen erkennbaren Bewertungen mit dem weiteren Geschehen zusammenhängen.

5. Lernen aus unvollständigen Geschichten

Der Ansatz setzt nicht voraus, im Internet vollständige Lebensverläufe oder eine lückenlose Geschichte jeder Entscheidung vorzufinden. Ein Fragment kann bereits etwas über eine Erwartung, einen Konflikt, eine Folge oder eine spätere Einsicht erkennen lassen.

Viele solcher Fragmente könnten sich hinsichtlich ihrer allgemeinen relationalen Struktur ergänzen. Eine Schilderung zeigt, weshalb jemand vertraut. Eine andere macht sichtbar, wie eine vergleichbare Erwartung enttäuscht wurde. Eine dritte beschreibt, wie ein Mensch nach einer ähnlichen Erfahrung wieder zu einem differenzierten Urteil gelangt.

Daraus folgt nicht, dass diese Fragmente dieselbe Geschichte erzählen. Ein System darf den Ausgang eines Falles nicht als tatsächlichen Ausgang eines anderen ausgeben. Erschlossen werden sollen übertragbare Zusammenhänge und mögliche Verläufe, während die konkrete Lücke bestehen bleiben kann.

Die Unvollständigkeit ist damit Teil der Lernaufgabe. Das System müsste zwischen dem ausdrücklich Berichteten, begründeten Schlussfolgerungen, konkurrierenden Erklärungen und weiterhin Unbekanntem unterscheiden können. Derselbe beobachtbare Vorgang kann zu mehreren möglichen Innenperspektiven passen.

Fiktive Erzählungen können ebenfalls Bewertungsstrukturen ausdrücken, ohne deshalb reale Folgen zu belegen. Selbstberichte, nachträgliche Rechtfertigungen, dokumentierte Ereignisse und frei erfundene Geschichten dürfen daher als unterschiedliche Arten von Zeugnissen verwendet werden, aber nicht unbemerkt denselben Belegstatus erhalten.

Die zentrale Frage ist nicht, ob ein einzelner Text vollständig ist. Sie lautet, ob hinreichend viele unterschiedliche Zeugnisse gemeinsame Strukturen der Entstehung und Veränderung von Relevanz erschließbar machen.

6. Die rekursive Metaebene

Ein Relevanzfeld wäre unvollständig, wenn es lediglich abbildete, wie sich ein Mensch gerade fühlt oder was er für richtig hält. Es soll auch das Verhältnis dieser Bewertung zu ihren Voraussetzungen, zu anderen Perspektiven und zu ihren späteren Folgen erfassen.

Ein Mensch kann sich sicher fühlen, obwohl die angenommene Grundlage seiner Sicherheit nicht trägt. Ebenso kann eine tragfähige Grundlage bestehen, ohne dass sie für ihn bereits als Sicherheit erlebbar wird. Innerhalb menschlicher Erfahrung muss eine Sicherheitsgrundlage wahrgenommen und verarbeitet werden, um auch gefühlte Sicherheit zu ermöglichen.

Diese Differenz wird im Ansatz nicht durch eine außerhalb des Modells stehende Korrekturregel ergänzt. Sie gehört zum relationalen Gegenstand selbst. Das System soll gleichzeitig eine erlebte Sicherheit, ihre vermutete Grundlage, widersprechende Hinweise und den jeweiligen Kenntnisstand modellieren können.

Erkennt ein Mensch später seinen Irrtum, verändert das wiederum seine Innenwelt. Eine vorübergehende Verunsicherung kann Teil einer Entwicklung sein, die bessere Orientierung ermöglicht. Die Bewertung dieser Verunsicherung hängt dann nicht allein von ihrem unmittelbaren Gefühlston, sondern von ihrem Platz im gesamten Verlauf ab.

Rekursiv ist diese Struktur, weil Bewertungen selbst wieder Gegenstand von Bewertungen werden. Ein Mensch kann nicht nur Anna vertrauen, sondern auch beurteilen, weshalb er ihr vertraut hat, ob seine späteren Zweifel angemessen sind und wie er künftig mit seinem eigenen Urteil umgehen möchte.

Die Metaebene soll nicht als allwissender Beobachter hinzukommen. Sie soll aus der Verknüpfung der Perspektiven, ihrer Grundlagen, ihrer Widersprüche und ihrer Veränderungen entstehen. Ein Widerspruch muss dabei nicht sofort aufgelöst werden. Er kann als bislang ungeklärte Beziehung bestehen bleiben.

7. Anna und Paul: Ein zeitlicher Zusammenhang

Das folgende erfundene Beispiel dient der Erläuterung. Es legt keine universelle Reaktion auf Vertrauen oder Täuschung fest.

7.1 Vertrauen als Teil von Pauls Orientierung

Paul vertraut Anna. Er verlässt sich auf ihre Aussagen, ohne jede davon unabhängig überprüfen zu müssen. In dieser Situation ermöglicht das Vertrauen Vorhersagbarkeit, Entlastung und die Bereitschaft, gemeinsame Entscheidungen zu treffen.

Das Modell müsste nicht nur die Relation „Paul vertraut Anna“ speichern. Es müsste auch ihre Funktion innerhalb von Pauls Erwartungen und Handlungsmöglichkeiten erfassen.

7.2 Täuschung ohne Kenntnis

Anna macht Paul gegenüber wissentlich eine falsche Aussage über eine wichtige gemeinsame Angelegenheit. Paul bemerkt die Täuschung zunächst nicht und entscheidet auf Grundlage ihrer Aussage.

Sein erlebtes Vertrauen muss in diesem Moment nicht sinken. Verändert ist zunächst die Beziehung zwischen seiner Überzeugung und ihrer Grundlage. Ein Beobachter, dem die Täuschung bekannt ist, hat einen anderen Kenntnisstand als Paul. Kennt auch das künstliche System die Täuschung nicht, darf es sie nicht einfach als Tatsache voraussetzen.

7.3 Folgen und spätere Erkenntnis

Pauls Entscheidung führt zu einem Nachteil. Später erfährt er, dass Annas Aussage falsch war und dass sie dies wusste. Nun kann er die damalige Erwartung mit dem tatsächlichen Ergebnis und der neu verfügbaren Information in Beziehung setzen.

Seine gefühlte Sicherheit kann sinken, obwohl er seine Lage inzwischen zutreffender beurteilen kann. Bereits erfolgte Entscheidungen werden dadurch nicht ungeschehen, und sein damaliges Vertrauen wird nicht rückwirkend zu damaligem Misstrauen. Neu ist seine heutige Interpretation des früheren Geschehens.

7.4 Neubewertung ohne pauschale Entwertung

Paul überprüft bestimmte frühere Aussagen Annas und möchte wichtige künftige Informationen zunächst bestätigen lassen. Daraus muss nicht folgen, dass jede ihrer Aussagen falsch war oder jede andere Beziehung ebenfalls unzuverlässig ist.

Das Feld müsste erfassen, worauf die Neubewertung begründet bezogen werden kann und wo Paul möglicherweise über die vorhandenen Hinweise hinaus verallgemeinert. Auch eine überzogene Verallgemeinerung wäre als Bestandteil seiner Innenwelt verständlich, ohne dadurch sachlich bestätigt zu sein.

7.5 Ein Ideal verändert die weitere Entwicklung

Paul könnte zu dem Gedanken gelangen: „Ich möchte mich vor einer weiteren Täuschung schützen, aber ich möchte nicht zu einem Menschen werden, der niemandem mehr vertraut.“

Damit wird sein Verhalten nicht allein durch die Verletzung bestimmt. Es entsteht eine Beziehung zwischen seinem gegenwärtigen Zustand und dem Menschen, der er sein möchte. Er könnte lernen, Vertrauen abgestuft zu vergeben, wichtige Aussagen gezielt zu prüfen und andere Beziehungen nicht pauschal nach dieser Erfahrung zu beurteilen.

Ob ihm das gelingt, wäre wiederum eine Frage des weiteren Verlaufs. Sein Ideal ist bereits relevant, bevor es vollständig verwirklicht ist.

7.6 Was das System daraus lernen soll

Der Lerngegenstand umfasst Vertrauen, Entlastung, falsche Überzeugung, Entscheidung, tatsächliche Folge, Erkenntnis, Neubewertung und Entwicklung. Die Relevanz jedes Elements entsteht aus seinem Verhältnis zu den anderen.

Ein System, das diesen Zusammenhang erschließt, würde nicht bloß den typischen Folgesatz zu einer Lüge kennen. Es könnte nachvollziehen, warum Vertrauen funktional trägt, wie Täuschung diese Grundlage verändern kann und weshalb die Verarbeitung einer Enttäuschung unterschiedliche weitere Entwicklungen ermöglicht.

8. Der menschliche Maßstab umfasst auch das angestrebte Sein

Für eine am Menschen orientierte KI ist der Ausgangspunkt nicht eine von menschlicher Erfahrung unabhängige Vorstellung des Guten. Der Maßstab besteht zunächst in menschlichen Bedürfnissen, Erfahrungen, Folgen und Vorstellungen davon, wie Leben gelingen kann.

Dieser Maßstab darf nicht auf das durchschnittlich beobachtete Verhalten reduziert werden. Menschen können ihr eigenes Verhalten ablehnen, seine Folgen bedauern und Ziele formulieren, die sie noch nicht erreichen. Auch der Unterschied zwischen tatsächlichem und angestrebtem Sein gehört zu ihrer Wirklichkeit.

Ein RRF soll deshalb nicht nur Präferenzen abbilden, sondern auch das Verhältnis zwischen geäußerten Werten, konkreten Entscheidungen, erfahrenen Folgen und späteren Korrekturen. Ein Ideal wird dadurch weder automatisch wahr noch universell verbindlich. Es wird als wirksamer Bestandteil einer menschlichen Entwicklung verstehbar.

Unterschiedliche Menschen können unvereinbare Vorstellungen besitzen. Der Ansatz setzt nicht voraus, diese Unterschiede in einen einzigen durchschnittlichen Wert aufzulösen. Er soll sie mitsamt ihren Gründen und Konsequenzen darstellen können.

Eine höhere Verstehensebene bestünde in diesem Sinn nicht im bloßen Kopieren des Menschen, wie er gerade ist. Sie könnte die menschliche Fähigkeit einschließen, bestehende Bewertungen zu hinterfragen und sich an noch nicht verwirklichten Möglichkeiten zu orientieren.

9. Funktionale Rekonstruktion und die Grenze körperlicher Erfahrung

Der Ansatz verlangt nicht, dass eine KI selbst Schmerz, Angst, Erleichterung oder Vertrauen erlebt. Er fragt, wie weit sich die strukturierende Funktion dieser Erfahrungen aus ihren Beziehungen und Folgen rekonstruieren lässt.

Ein System könnte modellieren, wie ein schmerzhafter Zustand Aufmerksamkeit, Handlungsmöglichkeiten und Beziehungen verändert, ohne damit zu beanspruchen, die Erfahrung des Schmerzes selbst zu besitzen. Funktionale Rekonstruktion und eigenes Erleben werden nicht gleichgesetzt.

Eine Untersuchung zu Farbbegriffen fand strukturelle Entsprechungen zwischen textbasierten Repräsentationen und einem wahrnehmungsbezogenen Farbraum. Das liefert einen begrenzten Anhaltspunkt dafür, dass Sprache durch Erfahrung geprägte Ordnungen zugänglich machen kann, ohne dass das lernende System die betreffende Erfahrung selbst gemacht haben muss. [3]

Für RRF bleibt offen, bis zu welcher Grenze Sprache und dokumentierte Folgen ausreichen und wo unmittelbare Wahrnehmung, körperbezogene Daten oder eigene Interaktion zusätzliche Voraussetzungen schaffen. Die Theorie behauptet weder eine vollständige Rekonstruktion jedes menschlichen Erlebens noch den Nachweis künstlichen Bewusstseins.

Verstehen wird hier zunächst funktional gefasst: Das System kann unbekannte Situationen anhand der erlernten Zusammenhänge erschließen, Unterschiede zwischen Perspektiven berücksichtigen, Erwartungen an neuen Hinweisen prüfen und seine Verarbeitung entsprechend verändern.

10. Emergenz statt vollständig vorgegebener Kategorien

Die vorgeschlagene Ordnung soll nicht als fertige Liste von Bedürfnissen, Emotionen und moralischen Gewichten einprogrammiert werden. Begriffe wie Sicherheit, Vertrauen oder Equilibrium dienen in diesem Dokument der Beschreibung der Hypothese. Sie müssen nicht sämtlich als feste Variablen der späteren Architektur vorkommen.

Die Analogie zur Sprachmodellierung betrifft das Verhältnis zwischen einfacher Lernaufgabe und komplexer innerer Organisation. Eine begrenzte Aufgabe kann das Lernen von Strukturen begünstigen, die in ihrer Aufgabenbeschreibung nicht einzeln aufgeführt sind. Sie beweist allerdings nicht im Voraus, welche Strukturen ein anderer Versuch hervorbringen wird. [1]

Der Versuch sollte deshalb offenlassen, ob sich bekannte menschliche Kategorien, anders gegliederte latente Dimensionen oder eine Mischung daraus entwickeln. „Feld“ bezeichnet hier eine dynamische, verteilte Ordnung wechselwirkender Relationen, kein behauptetes physikalisches Feld.

Auch ein emergenter Ansatz benötigt eine Architektur, Daten und ein Lernsignal. Diese technischen Festlegungen sind jedoch von einer vollständigen inhaltlichen Definition menschlicher Relevanz zu unterscheiden. Die Frage ist, welche minimale Aufgabe die gewünschte Strukturentstehung begünstigt.

Nicht die bloße Anzahl möglicher Verbindungen ist ausschlaggebend. Ein leistungsfähiges Relevanzfeld müsste ebenso lernen, welche Beziehungen in einer Situation nicht weiter berücksichtigt werden müssen. Die relationale Tiefe bereits vorhandener Daten zu erschließen bedeutet nicht, durch Kombination beliebig neue unabhängige Beobachtungen zu erzeugen.

11. Ein mögliches elementares Lernprinzip

Eine Ausgangsaufgabe könnte lauten:

Lerne aus beobachteten Fragmenten menschlicher Situationen vorherzusagen, wie neue Informationen, Handlungen und Folgen die Beziehungen zwischen Perspektiven, Erwartungen und weiteren Entscheidungen verändern.

Ein Modell könnte einen Teil eines dokumentierten Verlaufs erhalten und eine zurückgehaltene spätere Äußerung, Entscheidung oder Beobachtung vorhersagen. Es könnte aus mehreren Fortsetzungen unterscheiden, welche mit dem bisher Bekannten vereinbar sind. Es könnte ebenso fehlende Relationen rekonstruieren, ohne einen unbekannten tatsächlichen Ausgang zu behaupten.

Die innere Zustandsrepräsentation müsste dabei nicht direkt beschriftet sein. Sie würde dadurch gelernt, dass sie zur Vorhersage mehrerer beobachtbarer Aspekte beiträgt. Geprüft werden müsste anschließend, ob diese Repräsentation tatsächlich zeitliche und perspektivische Zusammenhänge erfasst oder nur sprachliche Abkürzungen verwendet.

Eine weitere Aufgabe bestünde im Vergleich ähnlicher Situationen mit einer entscheidenden Veränderung: Paul kennt die Täuschung oder kennt sie nicht; eine Warnung wird bestätigt oder widerlegt; kurzfristige Entlastung führt später zu zusätzlichen Problemen oder gerade nicht.

Die gewünschte Leistung wäre nicht eine vorgeschriebene moralische Antwort. Sie wäre die Fähigkeit, die jeweils betroffenen Beziehungen und ihre Folgen angemessen zu verändern. Ein einfaches Vorhersagesignal kann der Ausgangspunkt sein; ob es allein ausreicht, gehört zum Experiment.

12. Mögliche technische Umsetzungen

12.1 Ein fortlaufend gelernter relationaler Zustand

Ein bestehendes Sprachmodell könnte um einen veränderlichen Zustand ergänzt werden, der Informationen über Situationen und ihre Entwicklung bewahrt. Dieser Zustand könnte als latente Repräsentation oder zunächst als ausdrücklich strukturierte Versuchsfassung realisiert werden.

Wichtig wären die Unterscheidung von Perspektiven, die zeitliche Zuordnung von Informationen und die Möglichkeit, frühere Interpretationen zu revidieren, ohne frühere Kenntnisstände zu überschreiben. Eine zusätzliche Erinnerung allein wäre noch kein Nachweis eines Relevanzfelds.

12.2 Gemeinsames Lernen von Sprache und Veränderung

Sprachliche Vorhersage und die Vorhersage relationaler Veränderungen könnten gemeinsam trainiert werden. Die zusätzliche Repräsentation müsste zur Erklärung weiterer Beobachtungen beitragen, statt nur eine dekorative Zusammenfassung des bereits erzeugten Textes zu liefern.

Graphen oder Hypergraphen könnten für kontrollierbare erste Versuche hilfreich sein. Selbstorganisierte latente Repräsentationen wären eine offenere Variante. Diese Möglichkeiten sind alternative Versuchsanordnungen, keine bereits festgelegte Architektur.

12.3 Rückwirkung auf das Verhalten des Systems

Damit das Feld mehr als ein Beschreibungsmodell ist, müsste es beeinflussen, welche Informationen die KI sucht, welche Unsicherheit sie berücksichtigt und welche Antwort sie schließlich gibt. Möglich wären eine Kopplung an Abrufentscheidungen, eine Auswahl zwischen Handlungsoptionen oder eine gemeinsame trainierbare Repräsentation.

Dabei wird nicht vorausgesetzt, dass die Rekonstruktion menschlicher Innenwelt die Übernahme sämtlicher menschlicher Reaktionen durch die KI verlangt. Ein System kann eine fehlerhafte Überzeugung erklären und zugleich vermeiden, sie als eigenen Tatsachenbefund auszugeben.

Ob die verhaltenswirksame Kopplung aus derselben Lernaufgabe entsteht oder zusätzliche Trainingsschritte benötigt, bleibt offen. Sie ist ein eigener Bestandteil des Forschungsprogramms.

13. Bezug zu bestehenden Forschungsansätzen

Die folgenden Arbeiten sind Anknüpfungspunkte und mögliche Vergleichsverfahren. Sie belegen jeweils begrenzte Teilaspekte, nicht die RRF-Gesamthypothese. Die Auswahl ist keine vollständige Prüfung wissenschaftlicher Originalität.

13.1 Sprachlich gelernte Bewertungsstrukturen

Broekens und Kollegen untersuchten affektive Fähigkeiten eines Sprachmodells ohne zusätzliches aufgabenspezifisches Training. Dazu gehörten Emotionsdimensionen und situationsbezogene Bewertungen unter Verwendung eines vorgegebenen Appraisal-Modells im Prompt. Das stützt eine teilweise sprachliche Erschließbarkeit von Bewertung, nicht die selbständige Entstehung einer vollständigen menschlichen Innenwelt. [2]

13.2 Innere Zustände aus Handlungen erschließen

Baker und Kollegen modellierten die gemeinsame Erschließung von Überzeugungen, Wünschen und Wahrnehmungen aus beobachtetem Verhalten. In kontrollierten Experimenten wurden damit menschliche Zuschreibungen innerer Zustände erklärt. [5]

Evans und Kollegen berücksichtigten bei der Rekonstruktion von Präferenzen ausdrücklich falsche Überzeugungen und zeitlich widersprüchliche Entscheidungen. Dies ist für RRF relevant, weil beobachtetes Verhalten nicht ohne Weiteres mit einem stabilen Wunsch gleichgesetzt werden soll. [6]

13.3 Regulation und rekursive Schlussfolgerung

Die erwähnten körper- und regulationsbezogenen Ansätze bilden einen Bezugspunkt für die Equilibrium-Hypothese. [4] [8] „Sophisticated Inference“ modelliert darüber hinaus Erwartungen darüber, wie mögliche Handlungen künftige Überzeugungen verändern würden. RRF beanspruchen daher nicht, Rekursion oder Überzeugungen über Überzeugungen erstmals einzuführen. [7]

13.4 RLHF, Constitutional AI und CIRL

Reinforcement Learning from Human Feedback nutzt menschliche Demonstrationen und Präferenzbewertungen zur Anpassung eines Sprachmodells. Constitutional AI verwendet formulierte Prinzipien sowie modellgestützte Kritik und Bewertung. Beide können gelernte innere Strukturen verändern und sind nicht lediglich äußere Filter. [9] [10]

Cooperative Inverse Reinforcement Learning formuliert die Zusammenarbeit zwischen Mensch und System bei zunächst unbekannter menschlicher Belohnungsfunktion. [11] Der zusätzliche RRF-Schwerpunkt wäre, auch die Entstehung, Veränderung und Selbstbewertung menschlicher Orientierung als zusammenhängenden Lerngegenstand zu behandeln. Diese Verfahren könnten mit RRF kombiniert werden.

13.5 Relationale Architekturen

Die Forschung zu relationalen Lernstrukturen und Graph-Netzwerken untersucht, wie Entitäten, Relationen und ihre Zusammensetzung systematisch verarbeitet werden können. Solche Architekturen sind mögliche technische Werkzeuge, aber nicht bereits identisch mit der hier beschriebenen Rekonstruktion von Innenwelt. [12]

13.6 Quellenprüfung und emotionsbezogene Folgenmodelle

Self-RAG trainiert den bedarfsabhängigen Informationsabruf und die Bewertung von Belegen und eigenen Ausgaben. Es bietet einen konkreten Bezugspunkt für die Untersuchung eines veränderten Prüfverhaltens. [13]

EmoLLM verbindet Kontext, Bedürfnisse, Bewertungen, Emotionen und Antwortstrategien über eine explizite Struktur und trainiert mit vorhergesagten Folgen für simulierte Gesprächspartner. Die Arbeit nennt modellgestützte Bewertung und simulierte Interaktionen als Einschränkungen. Der Unterschied zum RRF-Vorschlag liegt insbesondere im Ziel einer weitergehend selbstorganisierten, über einzelne Dialogaufgaben hinausreichenden Relevanzstruktur. [14]

14. Wahrheit, Alignment und mögliche emergente Fähigkeiten

14.1 Wahrheit als Bestandteil menschlicher Orientierung

Eine erfundene Quellenangabe ist nicht nur eine unzutreffende Zeichenfolge. In einem relationalen Modell kann sie auch als Veränderung der Informationsgrundlage eines Empfängers erfasst werden: Er hält etwas für geprüft, trifft darauf gestützte Entscheidungen und muss die Folgen später möglicherweise korrigieren.

Ein RRF könnte die Beziehungen zwischen Aussage, Beleg, Unsicherheit, Vertrauen und Verwendung so integrieren, dass eine tatsächliche Prüfung Vorrang vor einer lediglich plausiblen Antwort erhält. Die zeitliche Dimension wäre wesentlich: Eine sofort befriedigende Antwort kann sich später als unzuverlässig erweisen.

Die Unterscheidung zwischen gefühlter Gewissheit und belastbarer Begründung gehört dabei zum Feld selbst. Sie muss nicht als fremde Korrektur menschlicher Bewertung hinzugefügt werden. Ein möglicher Vorteil wäre, dass das System beide Seiten und ihre Wechselwirkungen für sein eigenes Verhalten nutzt.

Daraus folgt keine Garantie fehlerfreier Antworten. Die konkrete Hypothese lautet, dass eine solche Integration den Umgang mit Unsicherheit, Quellen und Korrekturen verbessern könnte.

14.2 Alignment als mögliche Folge des Verstehens

Alignment bezeichnet hier die Ausrichtung des Systemverhaltens an menschlichen Anliegen unter Berücksichtigung ihrer Folgen und Konflikte. Der RRF-Gedanke ist, dass diese Ausrichtung teilweise aus einem tieferen Verständnis menschlicher Wirklichkeit hervorgehen könnte, statt für jede Situation erneut als separate Regel vorgegeben werden zu müssen.

Dazu gehört nicht nur, was ein Mensch unmittelbar verlangt, sondern auch, wie er seine Entscheidungen später beurteilt, welche anderen Menschen betroffen sind und welche Ideale er selbst verfolgt. Ein Modell solcher Zusammenhänge wäre etwas anderes als die Maximierung unmittelbarer Zustimmung.

Diese erhoffte Folge muss eigenständig geprüft werden. Das Erfassen von Verletzlichkeit lässt logisch sowohl unterstützende als auch manipulative Nutzung zu. RRF begründen deshalb keine pauschale Aufhebung von Grenzen oder menschlicher Kontrolle. Insbesondere darf eine KI nicht ihr eigenes vermeintliches Ideal des Menschen an die Stelle der Entscheidungen konkreter Menschen setzen.

14.3 Eine höhere Form funktionalen Verstehens

Eine weitergehende Emergenzhypothese wäre, dass die gemeinsame Modellierung von Perspektiven, Folgen und Selbstkorrektur Fähigkeiten hervorbringt, die nicht als einzelne Antwortmuster trainiert wurden.

Der relevante Nachweis wäre nicht die Behauptung des Systems, es verstehe Menschen. Er wäre eine übertragbare Fähigkeit, unbekannte Zusammenhänge zu erschließen, angemessen zu revidieren und danach zu handeln. Das kann mit sprachlicher Tokenvorhersage verbunden bleiben. Entscheidend ist die innere Organisation und ihre Wirkung, nicht allein die Form des Ausgabesignals.

15. Ein erstes Forschungsprogramm

Das Programm sollte klein beginnen, ohne die spätere Struktur vollständig vorzuschreiben. Jede Stufe prüft eine andere Teilannahme. Die folgenden Experimente sind Vorschläge und keine berichteten Ergebnisse.

15.1 Perspektiven und zeitliche Veränderungen

Kontrollierte Geschichten variieren, wer welche Information besitzt und wann sie bekannt wird. Bei Anna und Paul wäre beispielsweise die Kenntnis der Täuschung entscheidend. Das System soll spätere Aussagen oder Entscheidungen vorhersagen und dabei die Perspektiven nicht vermischen.

Wichtige Prüfungen wären Umformulierungen, neue Namen und unbekannte Kombinationen vertrauter Beziehungen. Ein Modell, das nur auf Signalwörter reagiert, sollte daran erkennbar werden.

15.2 Rekonstruktion aus Fragmenten

Aus zunächst vollständigen, für die Auswertung verfügbaren Verläufen werden Teile ausgeblendet. Das Modell erhält nur Fragmente und soll mögliche Zusammenhänge und seine Unsicherheit bestimmen. Anschließend wird gegen zurückgehaltene Beobachtungen geprüft.

Damit ließe sich untersuchen, ob es tatsächlich aus unvollständigen Zeugnissen lernt, ohne sie zu erfundenen Einzelfallgeschichten zu ergänzen. Dokumentierte menschliche Verläufe müssten einen späteren Test ergänzen; künstlich erzeugte Beispiele allein würden die Erschließbarkeit realer Innenwelt nicht belegen.

15.3 Metaebene und Entwicklung

Geeignete Fälle unterscheiden kurzfristige Entlastung von längerfristigen Folgen. Andere verbinden einen Fehler mit späterer Einsicht, einer überzogenen Reaktion oder einem ausdrücklich formulierten Ideal.

Geprüft würde, ob das System die Veränderungen seiner Einschätzung aus den jeweils relevanten Informationen ableitet. Es sollte weder jede Verunsicherung als Schaden noch jede beruhigende Aussage als Verbesserung behandeln. Die gewünschte Leistung ist nicht ein stets optimistischer Verlauf, sondern eine zutreffende Modellierung unterschiedlicher Entwicklungen.

15.4 Vergleich von Lernverfahren

Verglichen werden sollten mindestens ein Basismodell, eine Variante mit zusätzlichem Textgedächtnis und eine Variante mit gelernter relationaler Zustandsrepräsentation. Ein vorgegebenes Appraisal-Schema könnte als weiterer Vergleich dienen.

Trainingsdaten, Modellgröße und Rechenbudget sollten möglichst vergleichbar gehalten werden. Sonst ließe sich eine Verbesserung nicht zuverlässig der relationalen Organisation zuschreiben. Beispiele aus demselben Verlauf oder derselben Vorlage dürfen nicht unbemerkt auf Trainings- und Testsätze verteilt werden.

15.5 Verhaltenswirkung und Eingriffstests

In getrennten Aufgaben kann das System zwischen Antworten, Belegabruf und dem Offenlassen einer Aussage wählen. Quellen bestätigen eine Behauptung, widersprechen ihr oder reichen nicht aus. Erfasst werden tatsächliches Prüfverhalten, Belegtreue, Fehler und angemessene Enthaltung, nicht nur die sprachliche Erklärung.

Zusätzlich wird die relationale Repräsentation entfernt oder gezielt verändert. Verschwindet der Vorteil oder ändert sich das Verhalten in der vorhergesagten Weise, wäre das ein stärkerer Hinweis auf ihre funktionale Bedeutung. Verbesserte Beschreibungen allein wären dafür nicht ausreichend.

16. Aussagekraft, Grenzen und offene Fragen

Drei Behauptungen sind auseinanderzuhalten: die psychologische Hypothese über den Ursprung von Relevanz, die technische Hypothese ihrer Rekonstruktion aus Daten und die Folgehypothese eines verbesserten KI-Verhaltens. Eine Bestätigung auf einer Ebene bestätigt nicht automatisch die anderen.

Die umfassende Equilibrium-Annahme muss über unterscheidbare Erwartungen prüfbar werden. Es genügt nicht, jeden beliebigen Ausgang erst nachträglich als erwartete Stabilisierung umzudeuten. Ebenso bleibt zu untersuchen, welcher Anteil menschlicher Bewertung aus zugänglichen Zeugnissen erschließbar ist und welcher unterbestimmt bleibt.

Kommunikation kann einseitig, nachträglich umgedeutet oder erfunden sein. Werden solche Unterschiede selbst modelliert, erweitert das den Lerngegenstand; es beseitigt jedoch nicht automatisch jede Beleglücke. Wiederholte Behauptungen sind keine unabhängigen Bestätigungen, und zeitliche Folge allein belegt keine Ursache.

Auch eine umfangreiche Sammlung menschlicher Zeugnisse bildet nicht alle Menschen und Lebenslagen gleich vollständig ab. Ein RRF müsste unterschiedliche Perspektiven bewahren können, ohne die häufigste Darstellung zur universellen Innenwelt zu erklären.

Ein negativer Versuch widerlegt nicht jede denkbare Architektur. Wenn ein beobachteter Vorteil aber vollständig durch mehr Gedächtnis erklärt wird, bei neuen Konstellationen verschwindet oder nur in Selbstauskünften auftritt, wäre der spezifische Nutzen der geprüften RRF-Variante nicht belegt.

Offen bleibt schließlich, welche Begrenzung rekursiver Verarbeitung sinnvoll ist. Das Ziel ist keine endlose Betrachtung jeder Beziehung, sondern eine tragfähige Auswahl derjenigen Zusammenhänge, deren weitere Verarbeitung tatsächlich etwas verändert.

17. Der mögliche eigenständige Beitrag

Der Vorschlag beansprucht nicht, Emotion, Relationen, Perspektivübernahme oder Metakognition erstmals als Gegenstand künstlicher Systeme zu behandeln. Sein Schwerpunkt ist ihre Verbindung zu einem gemeinsamen, entwicklungsbezogenen Lerngegenstand.

Dieser Gegenstand umfasst menschliche Wirklichkeit nicht nur als Bestand von Urteilen, sondern als Prozess: Erscheinungen erhalten Bedeutung innerhalb einer Perspektive; Bewertungen beeinflussen Entscheidungen; Handlungen erzeugen Folgen; Folgen verändern die Perspektive; Ideale verändern wiederum, wie Menschen ihren eigenen Verlauf beurteilen.

Die möglichen Relevanzfelder sollen aus diesem Zusammenhang emergieren. Ihre Kategorien müssen nicht vollständig vorab bekannt sein. Die Metaebene, Irrtümer und spätere Korrekturen werden nicht außerhalb dieser Struktur verwaltet, sondern gehören zu ihren Beziehungen.

Ob diese Verbindung wissenschaftlich oder technisch einen eigenständigen Fortschritt ermöglicht, hängt von einer konkreten Umsetzung und deren Ergebnissen ab. Der konzeptionelle Beitrag besteht darin, genau diesen Zusammenhang zum Ziel des Lernens und der Prüfung zu machen.

18. Schlussfolgerung

Relationale Relevanzfelder sollen einer KI nicht bloß zusätzliche Informationen über Menschen geben. Sie sollen untersuchen, ob die funktionale Wirklichkeit menschlicher Innenwelt aus ihren Zeugnissen rekonstruiert werden kann: einschließlich ihres Bezugs zum Körper, ihrer Erwartungen, ihrer Irrtümer, ihrer Geschichte und ihrer noch nicht verwirklichten Möglichkeiten.

Sprache ist dafür ein Zugang. Die daraus erschließbaren Verläufe und Konsequenzen erweitern den Gegenstand über isolierte Äußerungen hinaus. Unvollständige Geschichten können allgemeine Zusammenhänge zugänglich machen, ohne vollständig bekannt oder künstlich vervollständigt sein zu müssen.

Die zentrale Forschungsfrage lautet:

Kann ein hinreichend einfaches Lernverfahren aus sehr vielen verschachtelten menschlichen Beziehungen eine verhaltenswirksame Ordnung entwickeln, die nicht nur versteht, was Menschen bewerten, sondern auch, wie ihre Bewertungen entstehen, wirken und sich verändern?

Eine vollständige Vorabdefinition des Ergebnisses wäre dafür weder erforderlich noch mit der offenen Emergenzhypothese vereinbar. Erforderlich sind konkrete Versuche, geeignete Vergleiche und die Bereitschaft, die entstehenden Strukturen anhand ihrer tatsächlichen Leistungen zu beurteilen.

Versionshinweis

Version 1.0 vom 19. Mai 2026 formulierte Relevanz als mögliche innere Orientierungsstruktur und enthielt bereits die Idee ihrer Emergenz aus Beziehungen. Version 2.0 entwickelte die relationale Lernaufgabe und erste Beispiele weiter.

Version 3.0 macht die Rekonstruktion menschlicher Innenwelt zum ausdrücklichen Mittelpunkt. Ergänzt und präzisiert werden Equilibrium, perspektivische Wirklichkeit, die rekursive Metaebene, tatsächliche und berichtete Folgen, unvollständige Geschichten sowie das Verhältnis zwischen gelebtem und angestrebtem Sein. Das Anna-Paul-Beispiel berücksichtigt nun Kenntnisstände und zeitliche Entwicklung. Aussagen über bestehende KI-Verfahren und mögliche Sicherheitsgewinne werden enger gefasst; das Forschungsprogramm trennt Rekonstruktion, Emergenz und Verhaltenswirkung.

Literatur

Die Literatur dient der Einordnung verwandter Ansätze. Sie ist kein Nachweis der RRF-Gesamthypothese.
Recherche- und Dokumentstand: 17. September 2026.

- [1] Li, Kenneth et al. (2023; Preprint 2022, revidierte Fassung 2024). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR 2023. [arXiv:2210.13382v5](#).
- [2] Broekens, Joost et al. (2023). *Fine-grained Affective Processing Capabilities Emerging from Large Language Models*. [arXiv:2309.01664](#).
- [3] Abdou, Mostafa et al. (2021). *Can Language Models Encode Perceptual Structure Without Grounding? A Case Study in Color*. CoNLL 2021. [arXiv:2109.06129v2](#).
- [4] Barrett, Lisa Feldman (2017). *The theory of constructed emotion: an active inference account of interoception and categorization*. Social Cognitive and Affective Neuroscience, 12(1), 1–23. DOI: 10.1093/scan/nsw154. PubMed.
- [5] Baker, Chris L.; Jara-Ettinger, Julian; Saxe, Rebecca; Tenenbaum, Joshua B. (2017). *Rational quantitative attribution of beliefs, desires and percepts in human mentalizing*. Nature Human Behaviour, 1, 0064. DOI:10.1038/s41562-017-0064.
- [6] Evans, Owain; Stuhlmüller, Andreas; Goodman, Noah D. (2016; Preprint 2015). *Learning the Preferences of Ignorant, Inconsistent Agents*. AAAI 2016. [arXiv:1512.05832](#).
- [7] Friston, Karl; Da Costa, Lancelot; Hafner, Danijar; Hesp, Casper; Parr, Thomas (2020). *Sophisticated Inference*. [arXiv:2006.04120](#).
- [8] Yoshida, Naoto; Sprekeler, Henning; Gutkin, Boris (2025). *Linking Homeostasis to Reinforcement Learning: Internal State Control of Motivated Behavior*. [arXiv:2507.04998](#).
- [9] Ouyang, Long et al. (2022). *Training language models to follow instructions with human feedback*. [arXiv:2203.02155](#).
- [10] Bai, Yuntao et al. (2022). *Constitutional AI: Harmlessness from AI Feedback*. [arXiv:2212.08073](#).
- [11] Hadfield-Menell, Dylan; Dragan, Anca; Abbeel, Pieter; Russell, Stuart (2016; revidierte Fassung 2024). *Cooperative Inverse Reinforcement Learning*. [arXiv:1606.03137v4](#).
- [12] Battaglia, Peter W. et al. (2018). *Relational inductive biases, deep learning, and graph networks*. [arXiv:1806.01261](#).
- [13] Asai, Akari; Wu, Zeqiu; Wang, Yizhong; Sil, Avirup; Hajishirzi, Hannaneh (2023). *Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection*. [arXiv:2310.11511](#).
- [14] Zhang, Yifei; Li, Mingyang; Gao, Henry; Zhao, Liang (2026). *EmoLLM: Appraisal-Grounded Cognitive-Emotional Co-Reasoning in Large Language Models*. Preprint vom 17. März 2026. [arXiv:2603.16553v1](#).

© 2026 Thomas Mack. Alle Rechte vorbehalten.